


斯坦福机器学习整理3——第三周

逻辑回归（Logistic Regression）

一种分类算法，其输出值一直在0到1之间。

假设函数： $h_{\theta}(x) = g(\theta^T x)$

$g(z) = \frac{1}{1 + e^{-z}}$ 称为Sigmoid Function或Logistic Function。如图



假设函数：

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

逻辑回归具体过程

1. 构造假设函数

构造假设函数，确定decision boundary（划分种类的边界），根据当 $\theta^T x \geq 0$ 时， $y = 1$ 。确定了 θ 就可以确定decision boundary。

2. 构造cost函数

拟合参数 θ 。

逻辑回归代价函数：

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}), y^{(i)})$$

$$\text{Cost}(h_{\theta}(x), y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

可以将 $\text{Cost}(h_{\theta}(x), y)$ 的两个等式合为一个：

$$\text{Cost}(h_{\theta}(x), y) = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$$

所以逻辑回归代价函数可以写成：

$$J(\theta) = -\frac{1}{m} \left[\sum_{i=1}^m y^{(i)} \log h_{\theta}(x^{(i)}) + (1 - y^{(i)}) \log(1 - h_{\theta}(x^{(i)})) \right]$$

3. 梯度下降法求使 $J(\theta)$ 最小的值

根据梯度下降法可以得到 θ 的更新过程：

$$\theta_j := \theta_j - \alpha \frac{\partial}{\partial \theta_j} J(\theta) = \theta_j - \alpha \frac{1}{m} \sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)}) x_j^{(i)}$$

求代价函数最小的方法

1. Gradient descent（梯度下降法）
2. Conjugated gradient（共轭梯度法）
3. BFGS
4. L-BFGs

后面三种方法的优点：1.不需要手动选择学习率 α ；2.收敛速度比梯度下降法要快。缺点是算法比梯度下降法要复杂。

正则化（Regularization）

改善或减少过拟合问题（overfitting）也称为高方差（High variance）。过拟合通常发生在当变量较多时，进行分类的代价函数最小值趋近与0。解决过拟合问题有两个方法：1.减少变量的数目（使用重要的变量，舍弃部分变量）2.正则化（使用所有的特征变量）

正则化：

$$J(\theta) = \frac{1}{2m} \left[\sum_{i=1}^m (h_{\theta}(x^{(i)}) - y^{(i)})^2 + \lambda \sum_{j=1}^n \theta_j^2 \right]$$

其中

$$\lambda \sum_{j=1}^n \theta_j^2$$

为正则化项， λ 为正则化参数。